
ACTIVIDAD 5

Actividad 5

Materia:	<i>Gestión de proyectos de inteligencia artificial</i>
Actividad:	<i>Actividad 5. Design thinking, definiendo e ideando</i>
Alumno(a):	<i>María Fernanda Olvera Pegueros</i>
Matrícula:	<i>AL07154082</i>
Docente:	<i>Luis Ariel Vázquez Piña</i>
Fecha de entrega:	<i>21 / 06 /2026</i>

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso / Prompt utilizado
ChatGPT / OpenAI	☒ Sí ☐ No	Apoyo en la revisión de redacción, explicación sobre la conexión y configuración de MLflow, así como orientación para la creación y organización de carpetas y archivos en GitHub.
Claude (Anthropic)	☐ Sí ☒ No	
Gemini (Google)	☐ Sí ☒ No	
Copilot (Microsoft)	☒ Sí ☐ No	Explicación de cómo conectar a MLflow.
Otra (especifica):	☐ Sí ☒ No	

Desarrollo de Contenido

1. Introducción

Dentro de la gestión de proyectos de inteligencia artificial es fundamental aplicar metodologías que permitan identificar problemas reales, definir necesidades del usuario y proponer soluciones basadas en datos. En esta actividad se desarrolló un modelo de aprendizaje automático orientado a la predicción del nivel de riesgo asociado a clientes con facturas pendientes de pago.

El objetivo principal fue construir un flujo completo de Machine Learning Operations, incluyendo preparación del dataset, entrenamiento de modelos, validación, comparación de resultados, registro de experimentos mediante MLflow y documentación del proyecto.

El problema planteado corresponde a un escenario financiero de gestión de cartera, donde la identificación temprana del riesgo permite priorizar acciones de cobranza.

Para resolverlo se implementaron dos algoritmos de clasificación:

- Regresión Logística.
- Random Forest.

Ambos modelos fueron evaluados utilizando métricas estandarizadas de clasificación y validación cruzada.

2. Desarrollo

Instrucciones

Selecciona al menos dos algoritmos, por ejemplo, regresión logística frente a random forest para clasificación, o regresión lineal frente a XGBoost para regresión, con el fin de realizar el entrenamiento, el ajuste y el registro. Asimismo, deberás definir métricas estandarizadas, ejecutar validación cruzada (k-fold o grid search) y registrar los resultados en MLflow.

1. Preparación del entorno y repositorio.

a. Crea un repositorio en GitHub con la siguiente estructura mínima:

```
Actividad5/  
├── datos/  
│   ├── datos_ini # datos originales  
│   └── datos_limp # datos limpios  
├── fuentes/  
│   └── entrena.ipynb # notebook de Colab (entrenamiento y  
evaluación)
```

```
| |— datos_prep.py # funciones de limpieza
| |— train.py # script de entrenamiento y registro en MLflow
| — README.md # guía de reproducción y decisiones
| — CHANGELOG.md # reporte final
```

b. Inicializa Git y conéctalo con GitHub.

2. Configura MLflow (seguimiento local o remoto) y valida que se registren parámetros, métricas y artefactos.

3. Genera el repositorio en GitHub.

a. Dataset versionado (o scripts de obtención).

b. Código en Python (.py) o notebook (.ipynb).

c. Evidencias de MLflow.

d. Archivo README.md documentado.

4. Reporte técnico en PDF.

Debe contener:

a. Descripción del dataset (documentar fuente, diccionario de datos y supuestos).

El dataset utilizado fue generado mediante inteligencia artificial generativa, considerando variables representativas de reportes históricos financieros y comportamiento de clientes.

El conjunto contiene:

- 1000 registros.
- 10 variables.
- Variable objetivo: riesgo.

Fuente: dataset sintético que simula información utilizada en casos reales de cuentas por cobrar.

Diccionario de datos

Variable	Descripción
id_cliente	Número del cliente.
id_factura	Número de factura.
monto_factura	Valor monetario de la factura pendiente.
dias_atraso	Número de días después de la fecha límite de pago.
historial_pago	Histórico de comportamiento de pago.
frecuencia_disputas	Cantidad de disputas registradas por cliente.
sentiment_email	Análisis de sentimiento obtenido de comunicaciones del cliente.
riesgo	Variable objetivo: nivel de riesgo (low, medium, high).
accion_recomendada	Acción sugerida.
fecha_factura	Fecha de emisión de la factura.

b. Proceso de limpieza y estandarización (manejo de valores nulos, tipos de datos, escalado o normalización, codificación de variables categóricas y reglas de negocio).

Debido a que el dataset fue generado artificialmente, no presentó valores nulos ni inconsistencias críticas.

Se realizaron las siguientes actividades:

Validación de datos

Se revisó:

- Tipos de datos.
- Valores únicos.
- Distribuciones.
- Relaciones entre variables.

Los tipos identificados fueron:

- Variables numéricas:
 - monto_factura
 - dias_atraso
 - historial_pago
 - frecuencia_disputas
- Variables categóricas:
 - sentiment_email
 - riesgo
 - accion_recomendada
- Variables identificadoras:
 - id_cliente
 - id_factura

Tratamiento de variables categóricas

Se utilizó One Hot Encoding, para transformar variables categóricas en valores numéricos.

c. Estrategia de versionamiento (registrar cambios en CHANGELOG.md o en el README).

El proyecto fue organizado mediante GitHub utilizando la estructura:

```
Actividad5/  
datos/  
└── datos_limp.csv
```

fuentes/

- Link Colab
- entrena.ipynb

CHANGELOG

README.md

Reporte Técnico - Actividad 5.pdf




Ilustración 1: Captura de GitHub. En el repositorio no se incluyeron los archivos datos_ini, ya que los datos fueron generados de manera sintética y se encontraban limpios desde el inicio. Las funciones de datos_prep.py y train.py están integradas dentro del notebook entrena.ipynb, donde se concentran las rutinas de preparación, entrenamiento y registro en MLflow.

d. Visualizaciones relevantes (identificación de patrones y anomalías).

Durante el análisis se identificaron los siguientes patrones:

Distribución de riesgo

Riesgo	Registros
High	644
Medium	303
Low	53

Se observa una mayor concentración de clientes con riesgo alto.

Relación riesgo - atraso

Promedio de días de atraso:

Riesgo	Días promedio
High	19.43
Medium	8.49
Low	2.30

Existe una relación directa entre incremento de días de atraso y mayor nivel de riesgo.

Relación riesgo - sentimiento

Los clientes con mensajes negativos presentaron mayor concentración en riesgo alto, indicando que el sentimiento puede ser una variable relevante para anticipar problemas de cobranza.

e. Descripción de los modelos entrenados.

Se desarrollaron dos modelos de clasificación multiclase.

Modelo 1: Regresión Logística

La regresión logística fue seleccionada debido a que se pretende una clasificación.

Modelo 2: Random Forest

Random Forest fue seleccionado debido a su capacidad para capturar relaciones no lineales entre variables.

f. Configuración de hiperparámetros.

Para validar el desempeño se utilizó:

- Train/Test Split.
- Validación cruzada con 5 particiones.
- Grid Search para Random Forest.

La validación permitió seleccionar la configuración con mejor desempeño promedio.

g. Métricas obtenidas (clasificación: accuracy, precision, recall, F1, ROC-AUC; regresión: MAE, RMSE, R²).

Las métricas utilizadas fueron:

- Accuracy.
- Precision.
- Recall.
- F1-score.
- ROC-AUC.

Resultados:

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	1.00	1.00	1.00	1.00	1.00
Random Forest	1.00	1.00	1.00	1.00	1.00

Validación cruzada:

Regresión Logística:

CV Accuracy = 0.999

h. Comparación estadística de resultados.

Los dos modelos presentaron resultados equivalentes en el conjunto de prueba.

Matrices de confusión:

Logistic Regression

```
[[129 0 0]
```

```
[0 11 0]
```

```
[0 0 60]]
```

Random Forest

```
[[129 0 0]
```

```
[0 11 0]
```

```
[0 0 60]]
```

Esto indica clasificación perfecta sobre los datos evaluados, debido a que el entrenamiento fue con datos sintéticos y limpios.

Sin embargo, al realizar pruebas adicionales con nuevos clientes se observaron diferencias:

Random Forest presentó mejor capacidad de generalización:

Accuracy prueba:

- Logistic Regression: 60%
- Random Forest: 80%

Siendo Random Forest una alternativa más robusta para escenarios futuros.

i. Evidencia del uso de MLflow.

Se configuró MLflow para registrar experimentos.

Experimentos registrados:

Run	Modelo
Logistic_Regression	Regresión Logística
Random_Forest	Random Forest

Métricas almacenadas:

- accuracy
- precision
- recall
- f1
- roc_auc
- parámetros del modelo

Evidencia visual:




Ilustración 2: Captura de panel de MLflow

URL generada:

<https://tuesday-peso-dedicator.ngrok-free.dev>

j. Reflexión sobre deuda técnica y MLOps.

Se identificaron posibles puntos de deuda técnica:

1. El dataset es sintético, por lo que sería necesario validar el comportamiento con datos reales antes de una implementación productiva.
2. La variable objetivo presenta una relación fuerte con algunas variables del dataset, lo que puede generar resultados demasiado optimistas.
3. Sería necesario implementar:

- Monitoreo del modelo.
- Control de deriva de datos.
- Reentrenamiento automático.
- Gestión de versiones del modelo.

MLflow permitió establecer trazabilidad del ciclo de vida del modelo, facilitando reproducibilidad, comparación de experimentos y control de resultados.

5. Recopila evidencias visuales.

a. Capturas del panel de MLflow.




Ilustración 2.2: Captura de panel de MLflow

b. Tablas o gráficas comparativas de desempeño.




Ilustración 3: Matriz de Confusión de Logistic Regression




Ilustración 4: Matriz de Confusión de Random Forest

Se observa que en el dataset sintético ambos fueron perfectos, pero en pruebas adicionales Random Forest generalizó mejor




Ilustración 5: Comparación de desempeño entre modelos

3. Conclusiones

El proyecto permitió aplicar un flujo completo de desarrollo de inteligencia artificial utilizando Design Thinking y MLOps.

Demostrando que los modelos de aprendizaje automático pueden apoyar procesos en el área de finanzas mediante la identificación de clientes con mayor probabilidad de riesgo.

Aunque ambos modelos alcanzaron métricas perfectas en evaluación inicial, Random Forest mostró mejor desempeño en pruebas prácticas con nuevos registros, por lo que representa una alternativa más adecuada futuras implementaciones.

Al integrar con MLflow permitió documentar experimentos, registrar métricas y mantener la trazabilidad del proceso.

La Actividad 5 no es un proyecto aislado, sino una complementación directa de la Actividad 4. Primero se definieron los riesgos, y ahora se confirma su impacto con evidencia estadística y modelos de machine learning.